Relatório técnico — Modelo Preditivo CardioIA

Fase 6 | Classificação de pico de risco em dados sintéticos

1. Objetivo e construção da base

O projeto utiliza 5.000 observações sintéticas (semente 42) com dez variáveis: idade média, carga do sistema, tempo de espera, frequência cardíaca, SpO_2, pressão sistólica, temperatura, densidade de eventos, eventos em 24 horas e disponibilidade de recursos. A variável binária pico_risco vale 1 quando ao menos duas das seis condições artificiais do enunciado são verdadeiras: carga > 80%, espera > 60 min, SpO_2 < 92%, FC > 110 bpm, eventos_24h > 4 ou recursos < 40%.

Essas variáveis misturam dados fisiológicos e operacionais. Logo, a previsão se refere a um indicador sintético de risco sistêmico, não à ocorrência clínica de infarto ou outro evento cardíaco.

2. Preparação e estratégia experimental

Foram usados dados gerados com NumPy/Pandas e divisão estratificada em 80% treino (4.000) e 20% teste (1.000), com random_state=42. No conjunto de treino, realizou-se validação cruzada estratificada de cinco partições (F1 como métrica de seleção). A Regressão Logística foi construída com StandardScaler dentro de Pipeline, evitando ajustar o escalonamento com dados do teste; Random Forest dispensa padronização.

3. Algoritmos e seleção

Foram comparados Regressão Logística e Random Forest. A floresta usa 250 árvores, min_samples_leaf=2 e random_state=42. Ela foi escolhida por capturar melhor os limiares e interações não lineares que geraram o alvo sintético.

Algoritmo	F1 médio (CV)	Desvio-padrão (CV)
Random Forest	0,9943	0,0035
Regressão Logística	0,6427	0,0313

4. Avaliação em teste independente

Na execução documentada do notebook, o Random Forest alcançou acurácia de 99,90%, precisão de 100%, recall de 99,62% e F1-score de 99,81%. A matriz de confusão registra um falso negativo e nenhum falso positivo em 1.000 exemplos. Esses valores se aplicam somente à distribuição sintética avaliada.

A acurácia expressa a fração total de acertos; a precisão mede a confiabilidade das predições positivas; o recall indica a fração dos casos positivos identificados; o F1 equilibra precisão e recall. O falso negativo é especialmente relevante em cenários de alerta, pois representa um caso de pico não sinalizado.

5. Interpretação, limites e melhorias

O desempenho elevado é esperado porque o rótulo foi definido por uma regra determinística sobre as mesmas variáveis de entrada. Isso não constitui validação clínica, nem garante calibração da probabilidade para pacientes reais. Além disso, há possível deslocamento de distribuição, ausência de fatores clínicos importantes e diferença entre limiares do alvo (por exemplo, SpO_2 < 92%) e dos protocolos (SpO_2 < 88%).

Como evolução, recomenda-se avaliar calibração (Brier score e curvas de calibração), robustez por subgrupos, sensibilidade a dados ausentes e alterações de distribuição, validação externa com dados autorizados e revisão de protocolos por especialistas. Em ambiente real, decisões críticas exigiriam supervisão humana e governança clínica.

6. Integração com o sistema multiagente

O classificador é salvo como modelo_risco.joblib, acompanhado da ordem das variáveis em colunas_modelo.json. O agente Analista de Risco invoca uma tool que carrega esses artefatos e retorna probabilidade, classe prevista e classificação; os agentes seguintes consultam protocolos determinísticos e geram uma resposta estruturada validada. Para o caso de demonstração, o histórico registra probabilidade 0,9916667 (99,17%) e classe ALTO.

Fontes do projeto: enunciado FIAP Fase 6; notebook CardioIA_Fase6_Modelo_Preditivo.ipynb; comparacao_modelos.csv; código src/core.py e src/multiagente.py; historico_execucao.json.